

SINTESI DEI CONTENUTI USATI PER L'ADDESTRAMENTO DEL MODELLO EX. ART 53 PAR. 1 LETT D) DEL REGOLAMENTO (UE) 2024/1689 - EU AI ACT

30.07.2026 – v3

Il presente documento contiene l'indicazione dei contenuti utilizzati per il training del modello ai sensi dell'art. 53 par. 1 lett d) del Regolamento n. 2024/1689 (EU AI Act), dalla fase di pre-training alla fase di fine-tuning.

Tale documentazione è **resa pubblicamente disponibile** con l'obiettivo di aumentare la trasparenza sui dati utilizzati nelle fasi di pre-addestramento e addestramento del modello di AI per finalità generali, **al fine di agevolare le parti con interessi legittimi** (inclusi i titolari del diritto d'autore e gli interessati) nell'esercitare e far rispettare i loro diritti ai sensi della normativa dell'Unione, rispettando al contempo i segreti industriali.

Tale documentazione deve essere di carattere generale e narrativo, anziché dettagliata sotto il profilo tecnico, deve cioè indicare le principali raccolte o serie di dati che sono state inserite nell'addestramento del modello, quali grandi banche dati o archivi di dati privati o pubblici.

1. Informazioni generali		
1.1 Identificazione del fornitore e recapiti	Nome e recapiti del fornitore	Fastweb S.p.A., Piazza Adriano Olivetti 1, 20139 Milano, Italia. Società a socio unico soggetta all'attività di direzione e coordinamento di Swisscom AG.
	Rappresentante autorizzato	N/A, fornitore stabilito in UE.
1.2 Identificazione del modello	Nome/i del modello e versione:	FastwebMIIA (Modello Italiano di Intelligenza Artificiale) • FastwebMIIA-7B

		FastwebMIIA-7B-2603
	Dipendenze del modello:	N/A
	Data di immissione sul mercato dell'Unione:	29/05/2025 (FastwebMIIA-7B) 23/03/2026 (FastwebMIIA-7B-2603)
	Descrizione del modello	FastwebMIIA è un auto-regressive Large Language Model (LLM) basato su un'architettura di dense decoder-only Transformer. Fastweb ha inserito alcuni moduli custom come il tokenizzatore, sviluppato in-house. Nella sua versione FastwebMIIA-7B-2603, il modello è ottimizzato per il function calling, per abilitare interazioni con strumenti esterni tramite chiamate a funzioni, ed il Contextual QA e per rispondere a domande su testi e documenti secondo il framework standard della RAG - Retrieval Augmented Generation. Il modello non presenta un rischio sistemico ai sensi dell'AI Act.
1.3. Modalità, dimensione complessiva dei dati di addestramento e altre caratteristiche	Modalità	☒ Testo ☐ Immagine ☐ Audio ☐ Video

		☐ Altro
	Dimensione dati di addestramento	☒ Testo - da 1 miliardo a 10.000 miliardi di token (circa $1,5 \times 2 \times 10^{12}$ token). Il modello è esclusivamente un modello testuale.
	Tipi di contenuto per dati testuali	A titolo meramente esemplificativo e non esaustivo: testi di narrativa e letteratura, testi scientifici ed educativi, pubblicazioni giornalistiche, documenti legali e ufficiali, informazioni promozionali, codice informatico, dati storici.
	Tipologia contenuti grafici	N/A Non presenti.
	Tipologia contenuti video	N/A Non presenti.
	Tipologia contenuti audio	N/A Non presenti
	Data più recente di acquisizione/raccolta dei dati per l'addestramento del modello	Maggio 2025
	Descrizione delle caratteristiche linguistiche dei dati di addestramento complessivi	Il modello è stato addestrato su un corpus eterogeneo di dati esclusivamente testuali, raccolti prevalentemente in lingua italiana e inglese, con una minore presenza di testi in altre lingue europee e non europee. La distribuzione linguistica riflette un focus specifico sull'italiano, al fine di garantire una buona performance del modello su questa lingua.

	Altre caratteristiche rilevanti dei dati di addestramento complessivi	Il dataset copre una vasta gamma di aree tematiche, tra cui: • Letteratura e scienze umane: testi narrativi, saggistica, filosofia, critica letteraria; • Materie scientifiche: testi relativi a matematica, fisica, biologia, informatica, ingegneria; • Scrittura di codice informatico: esempi di codice, principalmente python, documentazione tecnica; • Nozioni storiche e cultura generale: contenuti enciclopedici, fonti educative e divulgative; • Altri ambiti di uso generale: tra cui diritto, economia, arte, attualità e linguaggio conversazionale; • Scrittura creativa: contenuti da quotidiani e articoli divulgativi. Per quanto riguarda la modalità, i dati utilizzati sono esclusivamente testuali. Non sono stati inclusi dati multimodali (es. immagini, audio o video). Tutti questi dati sono stati utilizzati sia in formato 'plain text' durante la fase di pre-training, sia in formato Q&A o multiturn per le fasi di post-training.
	Ulteriori osservazioni	È stata predisposta una sezione di trasparenza pubblicamente accessibile, con l'obiettivo di fornire informazioni precise, chiare e in un linguaggio

		comprensibile su quanto realizzato per addestrare FastwebMIIA e sul suo funzionamento. Vedasi: FastwebMIIA - Prodotti Artificial Intelligence Grandi Aziende Fastweb
2. Elenco delle fonti dei dati		
2.1 Set di dati disponibili al pubblico	Sono stati utilizzati dataset pubblicamente disponibili per addestrare il modello?	☒ Sì
	Modalità dei contenuti coperti	☒ Testo
	Elenco dei set di dati di grandi dimensioni disponibili al pubblico	Common Crawl Archivio web pre-compilato, realizzato attraverso scraping non indiscriminato sul web, che rappresenta circa l'85% del corpus di addestramento totale. Secondo quanto dichiarato dalla stessa organizzazione, Common Crawl rispetta le regole "robots.txt" specificate dai siti web, che governano l'accesso dei web crawler ai loro contenuti e non effettua il crawling di pagine esplicitamente vietate da queste regole. Sono state utilizzate solo porzioni del dataset, selezionate tramite filtraggio qualitativo, filtraggio linguistico e deduplica. Periodo di raccolta: marzo 2024 – febbraio 2025 Si rinvia a Common Crawl - FAQ , in cui si esplicitano le attività di scraping condotte nel rispetto del protocollo robot.txt, e facendo inoltre il possibile per individuare e rispettare altre riserve espresse sui diritti

		ai sensi dell’art. 4, par. 3, Direttiva 2019/790
		RedPajama RedPajama-Data-v2 è un dataset aperto per il pre-training di LLM, costruito a partire da 84 snapshot di Common Crawl. Contiene oltre 30 trilioni di token filtrati e deduplicati (più di 100 trilioni di token grezzi) in cinque lingue: inglese, francese, spagnolo, tedesco e italiano. Periodo di raccolta: marzo 2024 – febbraio 2025
		FineWeb Edu – FineWeb Edu è un dataset aperto per il pre-training di LLM, derivato da FineWeb — a sua volta costruito a partire da Common Crawl. Contiene oltre 18,5 trilioni di token di testi in inglese, filtrati, deduplicati e selezionati per il loro contenuto di natura educativa. Periodo di raccolta: marzo 2024 – febbraio 2025
		Wikipedia - wikimedia/wikipedia - Datasets at Hugging Face Rappresenta circa l'1% del corpus di addestramento totale. Acquisito tramite libreria Hugging Face. Periodo di raccolta: marzo 2024 – febbraio 2025
2.2 Set di dati privati non disponibili al pubblico ottenuti da terze parti		
2.2.1 Dataset concessi in licenza dai titolari dei diritti o dai loro rappresentanti	Sono stati conclusi accordi di licenza commerciale con titolari dei diritti o con i loro rappresentanti?	☒ Sì
	Modalità dei contenuti coperti	☒ Testo

	Descrizione generale dei set di dati privati non di dominio pubblico ottenuti da terze parti	Contenuti editoriali, didattici, divulgativi e statistico-istituzionali in lingua italiana, acquisiti tramite accordi di licenza commerciale stipulati direttamente con i rispettivi titolari dei diritti. Tali accordi autorizzano espressamente l'utilizzo dei contenuti per finalità di addestramento di modelli di intelligenza artificiale.
2.2.2 Set di dati privati ottenuti da terze parti	Sono stati ottenuti dataset privati da terze parti non concessi in licenza come descritto nella Sezione 2.2.1?	☒ No
2.3 Dati ottenuti tramite crawling e scraping da fonti online	Sono stati utilizzati crawler dal fornitore o per conto del fornitore?	☒ No
	Ulteriori osservazioni	Fastweb non ha condotto alcuna attività diretta di crawling o scraping di fonti online. Tutti i dati provenienti da fonti online sono stati acquisiti esclusivamente attraverso dataset pre-compilati e pubblicamente disponibili come descritto nella Sezione 2.1. Nessun crawler proprietario è stato sviluppato o operato da Fastweb o per suo conto.
2.4 Dati degli utenti	Sono stati utilizzati dati provenienti dall'interazione degli utenti con il modello di AI (es. input e prompt degli utenti) per addestrare il modello?	☒ No
	Sono stati utilizzati dati raccolti dall'interazione degli utenti con altri servizi o prodotti del fornitore per addestrare il modello?	☒ No
	Ulteriori osservazioni	Nessun dato proveniente dall'interazione degli utenti con il modello è stato utilizzato

		per il training. Inoltre, i dati inseriti dagli utenti durante l'utilizzo di FastwebMIIA non vengono raccolti né utilizzati per attività di retraining o fine-tuning del modello. In nessun caso vengono utilizzati dati dei clienti di Fastweb per l'addestramento del modello. Per maggiori informazioni, vedasi la sezione "Data Journey" in FastwebMIIA - Prodotti Artificial Intelligence Grandi Aziende Fastweb
2.5 Dati sintetici	Sono stati creati dati sintetici generati da AI dal fornitore o per suo conto per addestrare il modello?	☒ Sì
	Modalità dei dati sintetici:	☒ Testo
	Modello/i di AI per finalità generali utilizzato/i per generare i dati sintetici:	Phi 3.5 (Microsoft), rilasciato sotto licenza MIT
	Dimensione	Inferiore all'1% del corpus di addestramento totale.
2.6 Altre fonti di dati	Sono state utilizzate fonti di dati diverse da quelle descritte nelle Sezioni 2.1-2.5 per addestrare il modello?	☒ No
3. Aspetti relativi al trattamento dei dati		
3.1 Rispetto della riserva di diritti concernenti le eccezioni o limitazioni relative all'estrazione di testo e di dati	Siete firmatari del Code of Practice per i modelli di AI per finalità generali che include impegni a rispettare le riserve dei diritti dall'eccezione TDM?	☒ Sì
	Descrivere le misure implementate prima dell'addestramento del modello per rispettare le riserve dei diritti	Fastweb ha utilizzato esclusivamente fonti autorizzate (dataset licenziati e partnership) e dataset pre-compilati pubblicamente disponibili (Common

	dall'eccezione TDM, inclusi i protocolli e le soluzioni di opt-out onorati dal fornitore	Crawl, RedPajama, FineWeb Edu) che, secondo quanto dichiarato dai rispettivi operatori, rispettano i protocolli robots.txt che governano l'accesso dei web crawler ai contenuti e non effettuano il crawling di pagine esplicitamente vietate da tali regole. È stato predisposto un canale di comunicazione pubblicamente accessibile per consentire ai titolari dei diritti di esercitare il proprio diritto di opt-out ai sensi dell'art. 4, par. 3, della Direttiva (UE) 2019/790. Per maggiori informazioni, vedasi la sezione “Riserva dei diritti” in FastwebMIIA - Prodotti Artificial Intelligence Grandi Aziende Fastweb
3.2 Rimozione dei contenuti illegali	Descrizione generale delle misure adottate per evitare o rimuovere dai dati di addestramento i contenuti illegali ai sensi del diritto dell'Unione	Fastweb mantiene e aggiorna regolarmente una blacklist di siti potenzialmente dannosi o contenenti dati personali, applicata per filtrare alla fonte gli URL presenti nei dati di Common Crawl. È stata altresì sviluppata una pipeline di pulizia dei dati personalizzata e progressiva, che incorpora le migliori pratiche presenti in letteratura, al fine di generare un corpus italiano progettato per l'addestramento di LLM specifici per la lingua. La pipeline prevede: • pulizia e normalizzazione dei dati testuali grezzi; • deduplica;

		• filtraggio basato sull'identificazione della lingua e sulla qualità semantica dei documenti; • rimozione delle Personal Identifiable Information (PII): per ciascun documento viene applicata un'euristica di rilevamento PII — se vengono rilevate meno di 5 istanze, queste vengono mascherate/rimosse, se ne vengono rilevate 5 o più, l'intero documento viene rimosso dal corpus; • selezione delle fonti con esclusione dei dataset contenenti informazioni sensibili o non conformi alle normative sulla privacy. Il corpus di addestramento è stato più volte bilanciato durante il processo di training per garantire la rappresentatività dei diversi domini e la copertura dei task desiderati.
3.3 Altre informazioni	Altre informazioni pertinenti sul trattamento dei dati	Occorre chiarire il progetto in cui si inserisce la presente valutazione. Per garantire l'efficace funzionamento di un modello di AI per finalità generali è fondamentale che lo stesso sia addestrato con dati testuali, nei quali possono essere anche compresi potenzialmente dati personali. Tali dati, infatti, sono essenziali per garantire un livello adeguato di conoscenza fattuale e contestuale,

		nonché per migliorare la comprensione e la generazione del linguaggio naturale. Fastweb, occorre precisarlo, non ha interesse a sfruttare direttamente dati personali in chiaro al fine di ottenere un beneficio economico diretto, ma di garantire l'efficacia di un modello linguistico di grandi dimensioni che solo per mezzo dell'addestramento tramite tali dati può risultare performante. Ed invero, senza l'impiego di tali informazioni, il modello risulterebbe limitato nella sua capacità di fornire risposte accurate e contestualizzate, compromettendo la sua utilità e affidabilità. E' per tale ragione che Fastweb ha necessità di trattare alcuni dati personali come, ad esempio, quelli relativi ad eventi storico-scientifici, fatti notori rilevanti sotto il profilo culturale globale, europeo o nazionale. L'addestramento di un modello linguistico di grandi dimensioni (LLM) comporta un equilibrio tra l'esigenza di utilizzare dati testuali, inclusi potenzialmente dati personali, e la necessità di garantire la tutela della privacy. Per ridurre al minimo il rischio per gli interessati, Fastweb ha implementato diverse misure di mitigazione, tra le quali: 1. selezione accurata delle fonti dati, escludendo dataset contenenti informazioni sensibili o non
--	--	---

		conformi alle normative sulla privacy; 2. pipeline di pulizia e anonimizzazione, che rimuove dati personali e informazioni identificabili prima dell'addestramento, assicurando minor impatto e presenza dei dati personali. In particolare, per ogni documento, viene applicata un'euristica di rimozione delle Personal Identifiable Information (PII), se presenti in numero inferiore a 5, altrimenti viene rimosso l'intero documento. Si sottolinea, infine, che la principale fonte di dati personali utilizzati per il training è Wikipedia, per la quale valgono le seguenti considerazioni: 1. l'insieme delle versioni utilizzate, in italiano ed inglese, rappresenta solo circa l'1% dell'intero corpus di dati utilizzati; 2. Wikipedia contiene in larga misura informazioni di personaggi storici o famosi (le cui informazioni sono di facile accesso pubblico in ogni caso) o legati a fatti di cronaca esposti mediaticamente (riportate in atti pubblici); 3. la natura principalmente enciclopedica dei contenuti e dei
--	--	---

		dati personali ivi pubblicati fa propendere per una bassa rischiosità del trattamento degli stessi; 4. la pipeline di pulizia per le fonti provenienti da Internet descritta sopra, comprensiva anche di forme di esclusione e masking delle informazioni riferite a persone fisiche identificate o identificabili, viene applicata per tutte le fonti ad eccezione di Wikipedia. Non sono presenti immagini nel dataset usato. È stata predisposta una sezione di trasparenza pubblicamente accessibile a questo link, con l'obiettivo di fornire informazioni precise, chiare e in un linguaggio comprensibile su quanto realizzato per addestrare FastwebMIIA e sul suo funzionamento. La sezione descrive il data journey dei dati personali attraverso tutte le fasi del ciclo di vita del modello e documenta le misure adottate per assicurare il rispetto degli standard legali ed etici stabiliti dall'AI Act, dalla Direttiva Copyright e dal GDPR. È inoltre presente un canale di comunicazione diretto per l'esercizio dei diritti degli interessati.
--	--	--